



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 1/13

NIM	
Nama	
Kelas	
Program Studi	
Asisten	

LANGKAH KERJA

Lakukan clustering pada dataset palmer-penguins. Langkah langkah

1. Normalisasikan dataset palmer-penguins menggunakan normalisasi minmax

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.preprocessing import MinMaxScaler
from sklearn.cluster import KMeans

df = pd.read_csv('palmer-penguins.csv')

if len(df.columns) == 1:
    with open('palmer-penguins.csv', 'r') as f:
        header = f.readline().strip().replace('"', '').split(',')
        df = df.iloc[:, 0].str.split(',', expand=True)
        df.columns = header

cols_to_use = ['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm',
               'body_mass_g']

for col in cols_to_use:
    df[col] = pd.to_numeric(df[col], errors='coerce')

df = df.dropna(subset=cols_to_use)

combinations = [
```



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 2/13

```
( 'bill_length_mm', 'flipper_length_mm'),  
( 'bill_depth_mm', 'body_mass_g'),  
( 'bill_length_mm', 'bill_depth_mm'),  
( 'flipper_length_mm', 'body_mass_g')  
]  
  
scaled_data = {}  
scaler = MinMaxScaler()  
  
for col1, col2 in combinations:  
    data = df[[col1, col2]].copy()  
    data_scaled = scaler.fit_transform(data)  
    scaled_data[(col1, col2)] = pd.DataFrame(data_scaled, columns=[col1,  
col2])  
  
print("Data berhasil dinormalisasi menggunakan MinMax Scaler.")
```

Output :

```
Data berhasil dinormalisasi menggunakan MinMax Scaler.
```

2. Tampilkan scatter plot sebelum clustering

```
fig_seb, axes_seb = plt.subplots(2, 2, figsize=(12, 10))  
fig_seb.suptitle('Scatter Plot Sebelum Clustering', fontsize=16)  
  
for idx, (col1, col2) in enumerate(combinations):  
    ax = axes_seb.flatten()[idx]  
    d = scaled_data[(col1, col2)]  
    ax.scatter(d[col1], d[col2], c='dodgerblue', alpha=0.7, edgecolors='w',  
s=50)  
    ax.set_title(f'{col1} vs {col2}')  
    ax.set_xlabel(col1); ax.set_ylabel(col2)
```




Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
K-Means Clustering
Bahasan :
Halaman : 3/13

```
plt.tight_layout()  
plt.show()
```

Output :



3. Clusterlah dataset palmer-penguins dengan nilai K 2, 3, 4

```
models = {}  
wcscs_dict = {}
```



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 4/13

```
for cols in combinations:
    d = scaled_data[cols]
    models[cols] = {}
    wcss = []

    for k in range(1, 11):
        kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
        kmeans.fit(d)
        wcss.append(kmeans.inertia_)

        if k in [2, 3, 4]:
            models[cols][k] = kmeans

    wcss_dict[cols] = wcss

print("Proses K-Means Clustering untuk K=2, 3, dan 4 selesai dilakukan.")
```

Output :

```
Proses K-Means Clustering untuk K=2, 3, dan 4 selesai dilakukan.
```

4. Tentukan K terbaik jika dilakukan dengan analisis Elbow Method

```
fig_elb, axes_elb = plt.subplots(2, 2, figsize=(12, 10))
fig_elb.suptitle('Elbow Method untuk Setiap Kombinasi', fontsize=16)

for idx, cols in enumerate(combinations):
    ax = axes_elb.flatten()[idx]
```



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 5/13


```
ax.plot(range(1, 11), wcss_dict[cols], marker='o')  
ax.set_title(f'{cols[0]} vs {cols[1]}')  
ax.set_xlabel('Jumlah Cluster (K)')  
ax.set_ylabel('WCSS')  
  
plt.tight_layout()  
plt.show()
```



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 6/13

Output :



5. Tampilkan scatter plot setelah clustering

```
for cols in combinations:  
    fig_aft, axes_aft = plt.subplots(1, 3, figsize=(18, 5))  
    fig_aft.suptitle(f'Setelah Clustering: {cols[0]} vs {cols[1]}',  
                    fontsize=16)
```




Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 7/13

```
for i, k in enumerate([2, 3, 4]):  
    km = models[cols][k]  
    d = scaled_data[cols]  
    axes_aft[i].scatter(d[cols[0]], d[cols[1]], c=km.labels_,  
cmap='viridis', alpha=0.6)  
    axes_aft[i].scatter(km.cluster_centers_[0], km.cluster_centers_[1],  
c='red', marker='X', s=100)  
    axes_aft[i].set_title(f'K = {k}')  
    axes_aft[i].set_xlabel(cols[0]); axes_aft[i].set_ylabel(cols[1])  
  
plt.tight_layout()  
plt.show()
```


Output :





Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 8/13



6. Analisislah perbandingan scatter plot sebelum clustering dan setelah clustering

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.cluster import KMeans
```




Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 9/13

```
from sklearn.preprocessing import MinMaxScaler

raw_df = pd.read_csv("palmer-penguins.csv")
if len(raw_df.columns) == 1:
    df = raw_df.iloc[:, 0].str.strip('"').str.split(',', expand=True)
    df.columns = raw_df.columns[0].strip('"').split(',')
else:
    df = raw_df.copy()

numeric_cols = ['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm',
                'body_mass_g']
for col in numeric_cols:
    df[col] = pd.to_numeric(df[col], errors='coerce')
df = df.dropna(subset=numeric_cols)

feature_pairs = [
    ('bill_length_mm', 'flipper_length_mm'),
    ('bill_depth_mm', 'body_mass_g'),
    ('bill_length_mm', 'bill_depth_mm'),
    ('flipper_length_mm', 'body_mass_g')
]

for x_col, y_col in feature_pairs:
    data_points = df[[x_col, y_col]].copy()

    scaler = MinMaxScaler()
    scaled_data = scaler.fit_transform(data_points)
```



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
K-Means Clustering
Bahasan :
Halaman : 10/13

```
kmeans = KMeans(n_clusters=3, n_init=10, random_state=42)
clusters = kmeans.fit_predict(scaled_data)
centroids = scaler.inverse_transform(kmeans.cluster_centers_)

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 5), sharey=True)
fig.suptitle(f"Analisis Clustering: {x_col} vs {y_col}", color='#003366',
fontsize=14, fontweight='bold')

ax1.scatter(data_points[x_col], data_points[y_col], color='#B0C4DE',
alpha=0.7, edgecolor='#4682B4', linewidth=0.5)
ax1.set_title("Distribusi Data (Original)", color='#004080')
ax1.set_xlabel(x_col)
ax1.set_ylabel(y_col)
ax1.set_facecolor('#F0F8FF')

sns.scatterplot(data=data_points, x=x_col, y=y_col, hue=clusters,
palette='viridis', ax=ax2, legend=False, edgecolor='white', s=60)

ax2.scatter(centroids[:, 0], centroids[:, 1], c='red', marker='X', s=200,
edgecolor='black', label='Centroids')

ax2.set_title("Hasil Pengelompokan (K=3)", color='#004080')
ax2.set_xlabel(x_col)
ax2.set_facecolor('#F0F8FF')
ax2.legend()


plt.tight_layout(rect=[0, 0, 1, 0.95])
plt.show()
```



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 11/13

Output :



7. Tentukan manakah k terbaik jika dilakukan analisis secara visual

Tugas no 1 – 6 dilakukan terhadap kombinasi atribut

- bill_length_mm - flipper_length_mm
- bill_depth_mm - body_mass_g



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
K-Means Clustering
Bahasan :
Halaman : 12/13

- bill_length_mm - bill_depth_mm
- flipper_length_mm - body_mass_g

Tuliskan kode program & output di sini

HASIL DAN ANALISIS DATA

Dataset palmer-penguins telah berhasil dikelompokkan menggunakan K-Means setelah melalui tahap pembersihan data dan normalisasi Min-Max. Berdasarkan evaluasi *Elbow Method* dan observasi *scatter plot*, nilai *cluster* yang paling ideal berada pada K=2 dan K=3, tergantung dari kombinasi atributnya. Pada sebaran data yang membentuk tren linier (seperti flipper_length_mm vs body_mass_g), K=2 membagi kelompok secara paling natural. Sedangkan pada sebaran data yang menyebar dan membentuk banyak titik pusat (seperti bill_length_mm vs bill_depth_mm), penggunaan K=3 terbukti lebih optimal karena *centroid* dapat menduduki tiap konsentrasi data tanpa saling tumpang-tindih.

KESIMPULAN

Algoritma K-Means terbukti efektif untuk melakukan segmentasi karakteristik fisik pada dataset penguin ini. Dari hasil praktikum, dapat disimpulkan bahwa untuk menentukan jumlah *cluster* (K) yang paling akurat, kita tidak bisa hanya bergantung pada satu indikator. Penggabungan antara validasi matematis (analisis penurunan nilai WCSS pada *Elbow Method*) dengan observasi visual (*Scatter Plot* sebelum dan sesudah *clustering*) adalah cara terbaik untuk menghasilkan pengelompokan yang tepat dan merepresentasikan data aslinya.

Link Google Colab

 LKM 4 K-Mean Clustering

Link Youtube (Unlisted)

 LKM 4_A_Kavin Noval Pratama

Jember,2026

Mengetahui,



Lembar Kerja Mahasiswa

Mata Kuliah : Data Mining
Bahasan : K-Means Clustering
Halaman : 13/13

Dosen Datamining

Asisten,

Fajrin Nurman Arifin, S.T., M.Eng
NIP. 198511282015041002

(Nama Jelas)
NIM.